

PROJETO SEMANTIX

Previsão de Admissões e Desligamentos no Mercado de Trabalho Brasileiro

Um modelo de Machine Learning treinado com dados oficiais do CAGED/RAIS

Lucas Prado Castelo | Ebac – Cientista de Dados | Setembro de 2026

O problema

- Toda contratação ou demissão no Brasil gera um registro oficial nas bases do governo (CAGED/RAIS).
- Será que é possível olhar para um desses registros e descobrir automaticamente se ele representa uma ADMISSÃO ou um DESLIGAMENTO?
- Entender esse padrão ajuda empresas, times de RH e formuladores de políticas públicas a monitorar e antecipar tendências do mercado de trabalho.


Objetivo do projeto

- Construir um modelo de Machine Learning que classifique corretamente cada registro como admissão ou desligamento.
- Validar esse modelo com dados reais de 2018 e 2019 — anos que o modelo nunca viu durante o treinamento.
- Ir além do notebook: entregar um executável, um programa simples que qualquer pessoa pode usar para analisar novas planilhas de dados e obter previsões na hora, sem escrever uma linha de código.

De onde vêm os dados


- Fonte: CAGED/RAIS — bases públicas e oficiais do governo brasileiro sobre contratações e demissões.
- Período analisado: 2007 a 2019.
- Volume: 10.000 registros por ano, totalizando cerca de 130 mil registros.
- Os dados de 2018 e 2019 foram propositalmente reservados para o teste final, simulando dados "do futuro".

O caminho percorrido



O passo 7 (executável) é o diferencial deste projeto: transforma o modelo em uma ferramenta pronta para uso.


Perfil etário dos trabalhadores



- Concentração entre 18 e 40 anos.
- Picos próximos a 20, 25 e 30 anos.
- A partir dos 40, a frequência cai progressivamente, formando uma cauda até acima de 70 anos.


Distribuição por gênero

Distribuição de gênero dos trabalhadores




- Homens: aproximadamente 63,3% da base.
- Mulheres: aproximadamente 36,7% da base.
- Predominância masculina clara no mercado de trabalho formal analisado.

Distribuição por raça/cor



- Branca (53,5%) e Parda (33,1%) somam 86,6% da base.
- Preta: 5,6% | Não informado: 6,9%
- Amarela: 0,6% | Indígena: 0,3%


Salário ao longo dos anos




- Salário médio subiu de ~R\$680 (2007) para ~R\$1.550 (2017) — alta de mais de 125%.
- Crescimento praticamente contínuo, com leve aceleração a partir de 2012.
- Atenção: valores nominais, sem ajuste pela inflação do período.

Raça/cor por estado

- Padrão regional claro na composição racial dos trabalhadores.
- Sul (RS, SC, PR) e boa parte do Sudeste concentram os maiores percentuais de trabalhadores brancos.
- No Sul, essa categoria ultrapassa 75% nos três estados.



Escolaridade x salário



- Relação clara: quanto maior a escolaridade, maior o salário médio.
- Do nível Analfabeto até o Ensino Médio, o crescimento é gradual (de ~R\$680 a ~R\$1.010).


Como o modelo decide

- O modelo aprende observando milhares de registros históricos reais.
- Ele leva em conta diversas características de cada registro — por exemplo, o tipo de movimentação, a escolaridade e o salário.
- A partir disso, encontra padrões e combinações que um ser humano dificilmente perceberia analisando os dados manualmente.

RESULTADOS

Testamos vários modelos

Acurácia = percentual de previsões que o modelo acertou



Validação com dados reais e um executável de verdade

- O modelo foi aplicado aos dados de 2018 e 2019 (19.649 registros que ficaram de fora do treinamento).
- Resultado: 100% de acerto. Confirma que o modelo generaliza bem, e não apenas "decorou" os dados de treino.
- Mais do que isso: foi criado um executável próprio. Basta arrastar um arquivo CSV para a janela do programa — sem instalar nada, sem programar — e ele devolve a previsão, a acurácia e um relatório completo na hora.
- Poucos projetos de ciência de dados vão além do notebook. Este projeto entrega uma ferramenta pronta para o usuário final usar.

Conclusão

- Modelo confiável, validado em dados reais e nunca vistos, com 100% de acerto.
- Ferramenta prática entregue: um executável simples que qualquer pessoa pode usar, sem programar e sem entender de Machine Learning.
- Da pergunta de negócio até uma solução usável — não apenas um modelo dentro de um notebook.